

MUESTREO ESTRATIFICADO.

❖ En el muestreo estratificado, la población de N unidades es dividida en L estratos. De cada uno de ellos se eligen elementos para formar la muestra de tamaño n .

❖ Si la elección de las n unidades se hace por m.a.s., decimos que el muestreo es estratificado aleatorio.

❖ La división o clasificación de la población en estratos, se hace en base a un criterio, por ejemplo: geográfico, socioeconómico, género, etc.

❖ El número de estratos depende del problema en estudio, está intrínsecamente ligado a la investigación.

❖ Los estratos son heterogéneos entre si, e internamente homogéneos.

❖ Los estratos no se sobreponen y juntos forman la totalidad de la población, por lo que $N_1 + N_2 + \dots + N_L = N$

❖ Para obtener un beneficio de la estratificación, deben ser conocidos los valores de los N_i (es decir, el tamaño de cada subpoblación).

❖ El m. e. corrige algunas deficiencias presentadas por el m.a.s.


a) La muestra estratificada es más representativa de la población.

a) La precisión de los resultados entregados a través de I de C es mayor en m. e.

a) Para que las ventajas del m. e. se cumplan, los estratos formados deben ser mas o menos homogéneos.

❖ En resumen, la estratificación permite disminuir los errores de estimación subdividiendo una población que muestra algún grado de heterogeneidad (alta variabilidad), en subpoblaciones que sean internamente homogéneas (baja variabilidad)

En el m.e. se divide la población en subpoblaciones o estratos.



De cada una, se extrae una m.a.s. de tamaño n_i

Notaciones y definiciones

N = Tamaño de la población (conocido)

N_h = Número de elementos del estrato h (conocido)

n_h = Número de elementos del estrato muestral h , $\sum n_h = n$

$\mu_h = \bar{Y}_h$ = media del estrato h .

$\bar{y}_h$ = media muestral del estrato muestral h

$S_h^2 = \frac{1}{N_h - 1} \sum_{i=1}^{N_h} (y_{hi} - \bar{Y}_h)^2$ Varianza del Estrato h

$s_h^2 = \frac{1}{n_h - 1} \sum_{i=1}^{n_h} (y_{hi} - \bar{y}_h)^2$ Varianza muestral del Estrato muestral h

$$W_h = \frac{N_h}{N}$$

Ponderación del estrato h

$$f_h = \frac{n_h}{N_h}$$

Fracción de muestreo del estrato h.

$$\bar{Y} = \mu = \frac{1}{N} \sum_{h=1}^L \sum_{i=1}^{N_h} y_{hi} = \frac{1}{N} \sum_{h=1}^L \frac{Y_h}{N_h} N_h$$

Luego queda:

$$\mu = \bar{Y}_{estr} = \frac{1}{N} \sum_{h=1}^L N_h \bar{Y}_h$$

Es la media poblacional.

Estimador de μ y su Varianza

El estimador de μ utilizado en el muestreo estratificado: $\bar{y}_{estr}$

Se define como:

$$\bar{y}_{estr} = \sum_{h=1}^L \frac{N_h \bar{y}_h}{N} \quad \text{Donde}$$

$$N = \sum_{h=1}^L N_h$$

El estimador $\bar{y}_{estr}$, en general, no es el mismo que la media de la muestra.

$$\bar{y} = \sum_{i=1}^L \frac{n_h \bar{y}_h}{n}$$

Media muestral.

La varianza de $\bar{y}_{estr}$ es:

$$\sigma_{\bar{y}_{estr}}^2 = \frac{1}{N^2} \sum_{h=1}^L N_h^2 \left(\frac{N_h - n_h}{N_h} \right) \frac{S_h^2}{n_h}$$

con

$$S_h^2 = \frac{1}{N_h - 1} \sum_{i=1}^{N_h} (y_{hi} - \bar{y}_h)^2$$

Un estimador insesgado de la varianza de $\bar{y}_{estr}$ es:

$$\hat{\sigma}_{\bar{y}_{estr}}^2 = \frac{1}{N^2} \sum_{h=1}^L N_h^2 \left(\frac{N_h - n_h}{N_h} \right) \frac{s_h^2}{n_h}$$

con

$$s_h^2 = \frac{1}{n_h - 1} \sum_{i=1}^{n_h} (y_{hi} - \bar{y}_h)^2$$

Estimador de Y y su Varianza

Si $\hat{Y}_{estr} = N\bar{y}_{est}$ es el estimador del total poblacional Y , entonces:

La varianza estimada del total poblacional es:

$$\hat{\sigma}_{\hat{Y}}^2 = \sum_{h=1}^L N_h (N_h - n_h) \frac{s_h^2}{n_h}$$

s_h^2 : *varianza muestral del estrato h*

Estimador de P y su Varianza

Sea $P_h = \frac{A_h}{N_h}$ la proporción de unidades que poseen la característica A en el i-ésimo estrato de la población

Sea $p_h = \frac{a_h}{n_h}$ la proporción de unidades que poseen la característica A en la muestra respectiva.

Un estimador de la proporción total de población es:

$$\hat{P} = p_{est} = \sum_{h=1}^L \frac{N_h p_h}{N} = \sum_{h=1}^L W_h p_h$$

La varianza de este estimador p_{est} es :

$$V(p_{est}) = \frac{1}{N^2} [N_1^2 V(P_1) + \dots + N_L^2 V(P_L)] = \frac{1}{N^2} \sum_{h=1}^L N_h^2 \left(\frac{N_h - n_h}{N_h} \right) \cdot \frac{P_h Q_h}{n_h}$$

El estimador insesgado de esta varianza se obtiene

sustituyendo $\frac{P_h Q_h}{n_h}$ por $\frac{p_h q_h}{n_h - 1}$

La varianza estimada de la proporción muestral es:

$$\hat{V}(p_h) = \frac{N_h - n_h}{N_h} \left(\frac{p_h q_h}{n_h - 1} \right)$$

Ejemplo I

Una empresa publicitaria está interesada en determinar qué tanto debe enfatizar la publicidad televisiva en un determinado municipio y decide realizar una encuesta por muestreo para estimar el número promedio de horas por semana que se ve televisión en los hogares de este municipio. Éste comprende dos pueblos, pueblo A y pueblo B y un área rural. El pueblo A contiene fábricas y la mayoría de los hogares son trabajadores fabriles con niños en edad escolar. El pueblo B es un suburbio exclusivo de una ciudad vecina y consta de habitantes de edad mayor con pocos niños. Existen 155 hogares en el pueblo A, 62 en el pueblo B y 93 en el área rural. La empresa tiene tiempo y dinero suficiente para entrevistar $n=40$ hogares, y decide seleccionar muestras aleatorias de tamaño $n_1=20$ del pueblo A, $n_2=8$ del pueblo B y $n_3=12$ del área rural (luego aprenderemos a calcular los tamaños de muestra)

Y : Tiempo que se ve televisión, en horas por semana

Estrato1 pueblo A			
35	28	26	41
43	29	32	37
36	25	29	31
39	38	40	45
28	27	35	34

Estrato2 pueblo B	
27	25
15	10
4	30
41	
49	

Estrato 3 área rural		
8	32	11
14	21	24
12	20	
15	34	
30	7	

$$n_1 = 20$$

$$\bar{y}_1 = 33,9$$

$$s_1^2 = 35,358$$

$$N_1 = 155$$

$$n_2 = 8$$

$$\bar{y}_2 = 25,125$$

$$s_2^2 = 232,411$$

$$N_2 = 62$$

$$n_3 = 12$$

$$\bar{y}_3 = 19,00$$

$$s_3^2 = 87,636$$

$$N_3 = 93$$

A-. Estimación de la media poblacional μ

$$y_{estr} = \sum_{h=1}^L \frac{N_h y_h}{N} = \frac{1}{N} \sum_{h=1}^L N_h \hat{y}_h$$

$$y_{est} = \frac{1}{310} [155(33,9) + 62(25,125) + 93(19,0)] = 27,7 \text{ horas}$$

Promedio de horas por semana en que todos los hogares ven televisión

B-. Varianza estimada del estimador $\bar{y}_{est}$

$$\hat{\sigma}_{\bar{y}_{estr}}^2 = \frac{1}{N^2} \sum_{h=1}^L N_h^2 \left(\frac{N_h - n_h}{N_h} \right) \frac{S_h^2}{n_h} \quad \hat{\sigma}_{\bar{y}_{est}}^2 = 1,97$$

C-. Máximo de error de estimación de dos Des. Est.

$$e = 2 \cdot \sqrt{\hat{V}(\bar{y}_{est})} = 2,8 \text{ horas}$$

D-. Estimación del total poblacional estratificado Y

$$\hat{y} = N \cdot y_{est} = (310)(27,7) = 8587 \text{ horas}$$

E-. Varianza estimada del total poblacional estratificado

$$\hat{V}(Ny_{est}) = N^2 \hat{V}(y_{est}) = N^2 \frac{1}{N^2} \sum_{h=1}^L N_h \left(\frac{N_h - n_h}{N_h} \right) \left(\frac{s_h^2}{n_h} \right)$$

$$\hat{V}(N\bar{y}_{est}) = 189317$$

$$\sigma_{\hat{Y}} = \sqrt{189317} = 435,106$$

F-. Máximo de error de estimación de dos Des. Est.

$$2 \cdot \sqrt{\hat{V}(N\bar{y}_{est})} = 2\sqrt{189317} = 870,2$$

F-. Estimación de la proporción de hogares donde se ve el programa X.

La empresa quiere estimar la proporción de hogares en el municipio donde se ve el programa X. La muestra sigue siendo estratificada de tamaño $n = 40$ con una asignación proporcional. Las muestras aleatorias por estrato son: $n_1=20$, $n_2= 8$ y $n_3= 12$. Los resultados de las entrevistas en los 40 hogares son:

Estrato	tamaño de muestra	nº de hogares programa X	Prop. muestral
1	$n_1=20$	16	0,8
2	$n_2=8$	2	0,25
3	$n_3=12$	6	0,5

Estime la proporción de hogares donde se ve el programa X y fije un límite para el error de estimación.



El valor estimado de la proporción de hogares donde se ve el programa X esta dado por p_{est} , calculamos:

$$p_{est} = \frac{1}{N} \sum_{h=1}^L N_h p_h = \frac{1}{310} (155(0,8) + 62(0,25) + 93(0,5)) = 0,6$$

Para calcular la varianza del estimador p_{est} necesitamos estimar las varianzas de los estratos:

$$\hat{V}(p_1) = \frac{N_1 - n_1}{N_1} \left(\frac{p_1 q_1}{n_1 - 1} \right) = \frac{155 - 20}{155} \left(\frac{0,8(0,2)}{19} \right) = 0,007$$

$$\hat{V}(p_2) = \frac{62 - 8}{62} \left(\frac{0,25(0,75)}{7} \right) = 0,024$$

$$\hat{V}(p_3) = \frac{93 - 12}{93} \left(\frac{0,5(0,5)}{11} \right) = 0,02$$

Calculamos la varianza estimada de la proporción poblacional estratificada:

$$\hat{V}(p_{est}) = \frac{1}{N^2} [N_1^2 \hat{V}(p_1) + N_2^2 \hat{V}(p_2) + N_3^2 \hat{V}(p_3)]$$

$$\hat{V}(p_{est}) = \frac{1}{(310)^2} [(155)^2 (0,007) + (62)^2 (0,024) + (93)^2 (0,02)] = 0,0045$$

Luego el valor estimado de la proporción de hogares en el municipio donde se ve el programa X, con un límite para el error de estimación es:

$$p_{est} \pm z_{1-\frac{\alpha}{2}} \sqrt{\hat{V}(p_{est})} \Rightarrow 2\sqrt{0,0045} = 0,134$$

Y el intervalo de confianza de p_{est} es:

$$p_{est} \pm z_{1-\frac{\alpha}{2}} \sqrt{\hat{V}(p_{est})} \Rightarrow 0,6 \pm 0,134$$

Intervalos de confianza y Tamaños de muestras en m.e.

Criterios para el cálculo del tamaño total de la muestra en M.E.

En las fórmulas aparecen los tamaños muestrales n_h , ¿Cómo calculamos la cantidad de unidades que debemos seleccionar de cada estrato, para conformar la muestra de tamaño n ?

Se pueden fijar tamaños arbitrarios o adoptar algún criterio específico, como los siguientes

- a) Distribución constante: Mismo número de unidades de cada estrato.
- b) Distribución proporcional: número de unidades proporcional al tamaño del estrato.
- c) Distribución proporcional a la varianza del estrato.

Tamaños de muestras

❖ cuando se desea estimar la media poblacional μ

❖ cuando se desea estimar la proporción poblacional P

❖ Cálculo del tamaño de muestra cuando se desea estimar la media poblacional μ o el total poblacional Y

$$n = \frac{\sum_{h=1}^L N_h^2 \sigma_h^2 / w_h}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2}$$

Donde w_h es la fracción de observaciones asignadas al estrato h y σ_h^2 es la varianza poblacional para el estrato h ; así:

$$D = \frac{e^2}{z^2}$$

Para estimar μ

$$D = \frac{e^2}{z^2 N^2}$$

Para estimar Y

I- . Afijación constante

Este criterio adopta los n_h iguales a n/L ; es decir, todos los estratos aportan la misma cantidad de elementos.

$$n_h = \frac{n}{L} \quad \forall h$$

Para utilizar la formula del tamaño de la muestra anterior se deben obtener aproximaciones de las varianzas poblacionales, un método es utilizar las varianzas muestrales de un experimento previo y otro método puede ser utilizando la amplitud de variación de las observaciones dentro de cada estrato. Del teorema de Tchebysheff y la distribución normal la amplitud de variación debe ser aprox. De 4 a 6 desviaciones estándar.

Del Ejemplo I

Una encuesta anterior sugiere que las varianzas de los estratos son aprox. $\sigma_1^2 = 25$, $\sigma_2^2 = 225$, $\sigma_3^2 = 100$. Deseamos estimar la media poblacional mediante $\bar{y}_{est}$. Seleccione el tamaño de muestra para obtener un límite de error de estimación igual a 2 horas, si la asignación es constante (esto es: $w_1 = 1/3$, $w_2 = 1/3$, $w_3 = 1/3$). En otras palabras se debe tomar igual número de observaciones de cada estrato.

$$n = \frac{\sum_{h=1}^L N_h^2 \sigma_h^2 / w_h}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2}$$

Para estimar μ

Calculamos:

$$\sum_{h=1}^3 \frac{N_h^2 \sigma_h^2}{w_h} = \frac{(155)^2 (25)}{\left(\frac{1}{3}\right)} + \frac{(62)^2 (225)}{\left(\frac{1}{3}\right)} + \frac{(93)^2 (100)}{\left(\frac{1}{3}\right)} = 6991275$$

$$\sum_{h=1}^3 N_h \sigma_h^2 = (155)(25) + (62)(225) + (93)(100) = 27125$$

$$D = \frac{e^2}{z^2} = \frac{2^2}{2^2} = 1$$

Sustituyendo los valores:

$$n = \frac{\sum_{h=1}^L N_h^2 \sigma_h^2 / w_h}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2} = \frac{6991275}{96100 + 27125} = 56,7$$

El investigador debe tomar 57 observaciones distribuidas:

$$n_1 = n(w_1) = 57(1/3) = 19$$

$$n_2 = 19$$

$$n_3 = 19$$

Del Ejemplo I

Suponga que ahora deseamos estimar el total poblacional Y , con las mismas varianzas y con un límite de 400 horas para el error de estimación. Seleccione el tamaño de muestra apropiado con afijación constante.

$$n = \frac{\sum_{h=1}^L N_h^2 \sigma_h^2 / w_h}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2 N^2}$$

Para estimar Y

$$\sigma_1^2 = 25, \quad \sigma_2^2 = 225, \quad \sigma_3^2 = 100$$

Calculamos:

$$D = \frac{e^2}{z^2 N^2} = \frac{(400)^2}{2^2 N^2} = \frac{40000}{N^2}$$

$$\sum_{h=1}^3 \frac{N_h^2 \sigma_h^2}{w_h} = \frac{(155)^2 (25)}{\left(\frac{1}{3}\right)} + \frac{(62)^2 (225)}{\left(\frac{1}{3}\right)} + \frac{(93)^2 (100)}{\left(\frac{1}{3}\right)} = 6991275$$

$$\sum_{h=1}^3 N_h \sigma_h^2 = (155)(25) + (62)(225) + (93)(100) = 27125$$

$$N^2 D = N^2 \left(\frac{40000}{N^2} \right) = 40000$$

$$n = \frac{\sum_{h=1}^L N_h^2 \sigma_h^2 / w_h}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2} = \frac{6991275}{40000 + 27125} = 104,2$$

Se deben tomar 105 observaciones distribuidas:

$$n_1 = 35$$

$$n_2 = 35$$

$$n_3 = 35$$

La media es:

$$\bar{y}_{cons} = \sum_{h=1}^L \frac{N_h \bar{y}_h}{N}$$

La varianza es:

$$\begin{aligned} V(\bar{y}_{const}) &= \frac{1}{N^2} \sum_{h=1}^L N_h (N_h - n^2) \frac{S_h^2}{n^2} \\ &= \frac{1}{n^2 N^2} \sum_{h=1}^L N_h (N_h - n^2) S_h^2 \end{aligned}$$

La varianza se estima sustituyendo la varianza del estrato h S_h^2 , por la varianza muestral del estrato h s_h^2

II- . Afijación proporcional

El reparto del tamaño n de la muestra entre los L estratos, es proporcional a los tamaños de éstos:

$$n_h = \frac{n}{N} \cdot N_h = n \cdot \left(\frac{N_h}{\sum N_h} \right)$$

Una ventaja al usar esta descomposición de la muestra, es que el estimador $\bar{y}_{est}$ es simplemente la media muestral de toda la muestra, esto representa un importante ahorro de tiempo en algunas investigaciones.

$$n = \frac{\sum_{h=1}^L N_h \sigma_h^2}{N \cdot D + \frac{1}{N} \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2}$$

Para estimar μ

$$D = \frac{e^2}{z^2 N^2}$$

Para estimar γ

Del ejemplo I

La empresa publicitaria del ejemplo considera que las varianzas aproximadas que se usaron son erróneas y que las varianzas de los estratos son iguales. El valor común de σ_h fue aproximado por 10 en un estudio preliminar. La empresa desea estimar el número promedio de horas por semana que se ve la televisión en los hogares del municipio, con un límite para el error de estimación igual a 2 horas. Encuentre el tamaño de muestra y los tamaños de muestra por estrato necesarios para lograr esta exactitud.

$$n = \frac{\sum_{h=1}^L N_h \sigma_h^2}{N \cdot D + \frac{1}{N} \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2}$$

Para estimar μ

Calculamos:

$$\sum_{h=1}^3 N_h \sigma_h^2 = (155)(100) + (62)(100) + (93)(100) = 31000$$

$$D = \frac{e^2}{z^2} = \frac{2^2}{2^2} = 1$$

$$n = \frac{\sum_{h=1}^L N_h \sigma_h^2}{N \cdot D + \frac{1}{N} \sum_{h=1}^L N_h \sigma_h^2} = \frac{31000}{310(1) + (1/310)(31000)} = 75,6$$

La elección por estrato es:

$$n_1 = n \left(\frac{N_1}{N} \right) = n \left(\frac{155}{310} \right) = n(0,5) = 38$$

$$n_n = n \left(\frac{62}{310} \right) = n(0.2) = 15$$

$$n_3 = n \left(\frac{93}{310} \right) = n(0.3) = 23$$

Difiere del ejemplo anterior porque hemos supuesto que las varianzas por estrato son iguales

Estimador de la media es:

$$\bar{y}_{prop} = \sum_{h=1}^L \frac{n_h \bar{y}_h}{n} = \sum_{h=1}^L w_h \bar{y}_h$$

Estimador del total

$$\hat{Y}_{prop} = N \sum_{h=1}^L \frac{n_h \bar{y}_h}{n} = N \sum_{h=1}^L w_h \bar{y}_h$$

Si sustituimos en las expresiones anteriores para las varianzas de $\bar{y}_{est}$ y de $\hat{Y}_{est}$ los n_h por su valor en función de N_h tenemos:

Varianza del estimador de la media con afijación proporcional

$$\sigma_{\bar{y}_{prop}}^2 = \frac{N-n}{N^2 n} \sum_{h=1}^L N_h S_h^2$$

Varianza del estimador del Total con afijación proporcional

$$\sigma_{\hat{Y}_{prop}}^2 = (N-n) \sum_{h=1}^L \frac{N_h S_h^2}{n}$$

Si la Pobl. Es grande; es decir, la razón $\frac{n_h}{N_h} \leq 0.05 \forall h$ entonces la expresión anterior se simplifica:

$$\sigma_{\bar{y}_{prop}}^2 = \frac{1}{N n} \sum_{h=1}^L N_h S_h^2$$

Además, si todas las varianzas S_h^2 tienen el mismo valor: S_w^2 nos queda:

$$\sigma_{\bar{y}_{prop}}^2 = \frac{N - n}{N} \bullet \frac{S_w^2}{n}$$

Como estimadores insesgados de estas varianzas se utiliza el estimador ya conocido:

$$s_h^2 = \sum_{i=1}^{n_h} \frac{(y_{hi} - \bar{y}_h)^2}{n_h - 1} \quad h = 1, \dots, L$$

III- . Asignación de Neyman

De la ecuación fundamental observamos que los tamaños de muestra son proporcionales a la magnitud de la varianza poblacional. Parece razonable entonces, que aquellos que tienen mayor variabilidad sean representados por un tamaño de muestra mayor que aquellos que son más homogéneos. Bajo este criterio el tamaño de muestra para cada estrato es proporcional al producto del tamaño del estrato N_h , por su variabilidad representada por su desviación estándar. Los costos por observación son los mismos para todos los estratos.

En algunos problemas de muestreo estratificado, el costo por obtener información es el mismo para todos los estratos. Si los costos son desconocidos, podríamos suponer que los costos por observación son iguales y la muestra que se debe elegir es:

$$n = \frac{\left(\sum_{h=1}^L N_h \sigma_h \right)^2}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2}$$

$$D = \frac{e^2}{z^2 N^2}$$

La selección por estrato es:

$$n_h = n \left(\frac{N_h \sigma_h}{\sum_{h=1}^L N_h \sigma_h} \right)$$

Para estimar μ

Para estimar γ

Del Ejemplo I

La firma publicitaria del ejemplo, decide utilizar entrevistas por teléfono en lugar de entrevistas personales, porque todos los hogares en el municipio tienen teléfono y este método reduce los costos. El costo de obtener una observación es entonces el mismo en los tres estratos. Las desviaciones estándar son de nuevo aproximadas por $\sigma_1 = 5$, $\sigma_2 = 15$, $\sigma_3 = 10$. La empresa desea estimar la media poblacional μ , con un límite para el error de estimación igual a 2 horas. Encuentre el tamaño aproximado de la muestra n y los tamaños de muestras para los estratos:

$$n = \frac{\left(\sum_{h=1}^L N_h \sigma_h \right)^2}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2}$$

$$D = \frac{e^2}{z^2}$$

Para estimar μ

Calculamos

$$\sum_{h=1}^3 N_h \sigma_h = (155)(5) + (62)(15) + (93)(10) = 2635$$

$$\sum_{h=1}^3 N_h \sigma_h^2 = (155)(5)^2 + (62)(15)^2 + (93)(10)^2 = 27125$$

$$D = \frac{e^2}{z^2} = \frac{4}{4} = 1$$

$$n = \frac{\left(\sum_{h=1}^L N_h \sigma_h \right)^2}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2} = \frac{(2635)^2}{(310)^2 (1) + 27125} = 56,34$$

$$n_h = n \left(\frac{N_h \sigma_h}{\sum_{h=1}^L N_h \sigma_h} \right)$$

$$n_1 = n \left(\frac{(155)(5)}{2635} \right) = n(0.3) = (57)(0.3) = 17$$

$$n_2 = n \left(\frac{(62)(15)}{2635} \right) = (57)(0.35) = 20$$

$$n_3 = n \left(\frac{(93)(10)}{2635} \right) = (57)(0.5) = 20$$

Ejemplo II

Una investigadora quiso estimar el peso promedio de 90 ratas (50 machos y 40 hembras) que han sido alimentadas con cierta dieta. Las ratas fueron separadas por sexo; por lo que el uso de muestreo aleatorio estratificado con dos estratos pareció apropiado. Para aproximar la variabilidad dentro de los estratos, la investigadora seleccionó la rata más pequeña y la más grande en cada estrato y las pesó. Ella encontró que la amplitud de variación fue de 10 gramos para los machos y de 8 para las hembras. ¿Qué tan grande debió tomar la muestra para estimar el promedio poblacional con un límite de 1 gramo para el error de estimación?. Suponga que el costo fue el mismo para ambos estratos.

¿Qué criterio de afijación muestral usaría?

Criterio de Neyman

Denotemos los machos como estrato 1 y las hembras como el estrato 2.
Para utilizar este criterio debemos estimar las varianzas por estrato.
Suponiendo que los pesos tiene una distribución normal, entonces:

$$2\sigma - (-2\sigma) = 4\sigma = 10$$

$$\sigma_1 = 10/4 = 2,5$$

$$\sigma_2 = 8/4 = 2,0$$

$$\sum_{h=1}^2 N_h \sigma_h = (50)(2,5) + (40)(2,0) = 205$$

$$n_h = n \left(\frac{N_h \sigma_h}{\sum_{h=1}^L N_h \sigma_h} \right)$$

$$n_1 = n \left(\frac{125}{205} \right) = n(0.61)$$
$$n_2 = n \left(\frac{80}{205} \right) = n(0.39)$$

Entonces :

$$w_1 = 0.61 \text{ y } w_2 = 0.39$$

$$\sum_{h=1}^2 N_h \sigma_h^2 = (50)(2,5)^2 + (40)(2,0)^2 = 472,50$$

$$D = \frac{e^2}{z^2} = \frac{1^2}{2^2} = 0,25$$

$$n = \frac{\left(\sum_{h=1}^L N_h \sigma_h \right)^2}{N^2 D + \sum_{h=1}^L N_h \sigma_h^2} = \frac{(205)^2}{(90)^2 (0,25) + 472,50} = 16.83 \approx 17$$

La elección de las unidades de cada estrato es:

$$n_1 = n \cdot w_1 = (17)(0.61) = 10$$

$$n_2 = n \cdot w_2 = (17)(0.39) = 7$$

❖ Cálculo del tamaño de muestra cuando se desea estimar la proporción poblacional.

Tamaño de muestra aproximado que se requiere para estimar P , con un límite e , para el error de estimación.

$$n = \frac{\sum_{h=1}^L N_h^2 P_h Q_h / w_h}{N^2 D + \sum_{h=1}^L N_h P_h Q_h}$$

Donde w_i es la fracción de observaciones asignadas al estrato h ,
 P_h es la proporción poblacional del estrato h , y

$$D = \frac{e^2}{z^2}$$

Del Ejemplo I

Criterio de Neyman

Suponga que en el ejemplo I se van a efectuar entrevistas por teléfono, por lo que los costos de muestreo son los mismos en todos los estratos. Las Proporciones de los estratos P_h son desconocidas, pero pueden ser aproximadas por las proporciones de las muestras del ejercicio anterior; esto es:  Se desea estimar la proporción poblacional P_{est} con un límite de 0,1 para el error de estimación. Encuentre el tamaño de muestra para lograr este límite al costo mínimo.

$$n = \frac{\left(\sum_{h=1}^L N_h \sqrt{p_h q_h} \right)^2}{N^2 D + \sum_{h=1}^L N_h p_h q_h}$$

$$n_h = n \left(\frac{N_h \sqrt{p_h q_h}}{\sum_{h=1}^L N_h \sqrt{p_h q_h}} \right)$$

$$D = \frac{e^2}{z^2}$$

Porque los costos son todos iguales

$$\sum_{h=1}^3 N_h \sqrt{p_h q_h} = 155\sqrt{0,8(0,2)} + 62\sqrt{0,25(0,75)} + 93\sqrt{0,5(0,5)}$$

$$= 135,346$$

$$n_1 = n \left(\frac{N_1 \sqrt{p_1 q_1}}{\sum_{h=1}^3 N_h \sqrt{p_h q_h}} \right) = n \left(\frac{62,000}{135,346} \right) = n(0,46)$$

$$n_2 = n \left(\frac{26,846}{135,346} \right) = n(0,2)$$

$$n_3 = n \left(\frac{46,500}{135,346} \right) = n(0,34)$$

Entonces $w_1 = 0,46$, $w_2 = 0,20$ $w_3 = 0,34$

$$\sum_{h=1}^3 N_h p_h q_h = 59675$$

$$N^2 D = N^2 \frac{e^2}{z^2} = (310)^2 \frac{(0,1)^2}{2^2} = 240,25$$

$$n = \frac{\left(\sum_{h=1}^L N_h \sqrt{p_h q_h} \right)^2}{N^2 D + \sum_{h=1}^L N_h p_h q_h} = \frac{(135,346)^2}{240,25 + 59,675} = 61,08 \approx 62$$

La asignación correspondiente es:

$$n_1 = nw_1 = 62(0,46) = 29$$

$$n_2 = nw_2 = 62(0,20) = 12$$

$$n_3 = nw_3 = 62(0,34) = 21$$

Importante

Recuerde que la fórmula de asignación toma una forma muy simple cuando las varianzas así como los costos son iguales en todos los estratos. En nuestro caso necesitamos que los P_h sean iguales, La ecuación de asignación queda:

$$n_h = n \left(\frac{N_h}{N} \right) \quad h = 1, \dots, L$$

Recuerde que este método de asignación de los tamaños de muestra a los estratos es llamado asignación proporcional.

Ejemplo

El número total de habitantes de 64 ciudades, de cierto país, será estimado a través de una muestra de tamaño 24.

- a) Encontrar el error estándar del total estimado por m.a.s.
- b) Encontrar el error estándar del total estimado por un m.e.a, con asignación proporcional
- c) Encontrar el error estándar del total estimado por m.e.a. con 12 unidades obtenidas en cada estrato.

Las ciudades fueron divididas en dos estratos:

Estrato1		Estrato 2			
900		364	209	113	
822		317	183	115	
781		328	163	123	
805		302	253	154	
670		288	232	140	
1238		291	260	119	
573		253	201	130	
634		291	147	127	
578		308	298	100	
487		272	164	107	
442		284	143	114	
451		255	169	111	
464		270	139	163	
400		214	170	116	
366		195	150	122	
459	$N_h=16$	260	143	134	$N_h=48$

$$Y_1 = \sum_{i=1}^{16} y_{1i} = 10070$$

$$\sum_{i=1}^{16} y_{1i}^2 = 7.145.450$$

$$Y_2 = \sum_{i=1}^{48} y_{2i} = 9498$$

$$\sum_{i=1}^{48} y_{2i}^2 = 2.141.720$$

Calculamos Parámetros:

$$Y = Y_1 + Y_2 = 10.070 + 9.498 = 19.568$$

Total poblacional

$$S^2 = \frac{1}{N-1} \left[\sum_{i=1}^L y_i^2 - N \bar{y}^2 \right] = 9287170 - 64 \left(\frac{19568}{64} \right)^2$$

$$S^2 = 52.448$$

Es la varianza poblacional.

El objetivo del problema es comparar las estimaciones hechas por distintos tipos de muestreo.

I-. M.A.S. con $n= 24$ y $N=64$

$$\begin{aligned}\sigma_{\hat{y}}^2 &= Var(\hat{Y}) = Var(N\bar{y}) = N^2 Var(\bar{y}) \\ &= N^2 \frac{N-n}{N} \frac{S^2}{n} = N(N-n) \frac{S^2}{n} \\ &= 64(64-24) \frac{52448}{24} = 5594453\end{aligned}$$

La desviación estándar es:

$$\sigma_{\hat{Y}} = 2365$$

I-. M.E. con asignación proporcional.

$$\begin{aligned}\sigma_{\hat{y}}^2 &= Var(\hat{Y}) = Var(N\bar{y}_{prop}) = N^2 Var(\bar{y}_{prop}) \\ &= N^2 \frac{N-n}{N^2 n} \sum_{h=1}^L N_h S_h^2 = \frac{N-n}{n} \sum_{h=1}^L N_h S_h^2\end{aligned}$$

La varianza de cada estrato es:

$$S_i^2 = \frac{1}{N_i - 1} \sum_{i=1}^{N_h} (y_{1i} - \bar{Y}_i)^2$$

$$\begin{aligned}S_1^2 &= 53843 \\ S_2^2 &= 5581\end{aligned}$$

$$S_1 \sim 10 * S_2$$

Luego reemplazamos en la formula

$$\begin{aligned}\sigma_{\hat{y}_{prop}}^2 &= Var(\hat{Y}) = \frac{N-n}{n} \sum_{i=1}^L N_h S_h^2 \\ &= \frac{64-24}{24} (16(53843) + 48(5581)) = 1.882.293\end{aligned}$$

La desviación estándar es:

$$\sigma_{\hat{Y}_{prop}} = 1372$$

III-. M.E. con tamaño arbitrario $n_1=n_2=12$

$$\sigma_{\hat{Y}_{est}}^2 = N^2 \left(\frac{1}{N^2} \sum_{h=1}^L N_h (N_h - n_h) \frac{S_h^2}{n_h} \right)$$

$$\begin{aligned} \sigma_{\hat{Y}_{est}}^2 &= \frac{16(16-12)}{12} (53843) + \frac{48(48-12)}{12} (5581) \\ &= 1.090.827 \end{aligned}$$

La desviación estándar es:

$$\sigma_{\hat{Y}_{est}} = 1044$$

De los 3 valores obtenidos, el más pequeño se obtiene del diseño estratificado con tamaño arbitrario, luego si construyéramos un intervalo de confianza para el total poblacional, considerando sólo 24 unidades, el tercer procedimiento de muestreo nos daría un intervalo más preciso (más pequeño), que los otros dos.

De los dos primeros, el m.e. con afijación proporcional da una estimación más precisa.